

Atelier N° 02 : Manipulation avancée de HDFS et MapReduce **sous Docker**



→ Objectifs

- Manipuler les fichiers et répertoires dans HDFS (création, suppression, lecture, copie).
- Comprendre la logique de réplication et tolérance aux pannes.
- Lancer et analyser des jobs MapReduce.
- Visualiser et interpréter les résultats des traitements dans HDFS.
- Suivre et diagnostiquer les jobs dans les interfaces Web Hadoop.

🚦 Cet atelier est à rendre via [ce lien](#)

Partie 1 : Vérification et préparation de l'environnement

→ Étape 1 : Démarrage du cluster Hadoop sous Docker

```
➤ docker compose up -d
```

→ Étape 2 : Accéder au conteneur principal (NameNode)

```
➤ docker exec -it namenode bash
```

→ Étape 3 : Vérifier les services Hadoop

```
➤ jps
```

→ Étape 4 : Accès aux interfaces Web

- NameNode UI : <http://localhost:9870>
- YARN UI : <http://localhost:8088>

Partie 2 — Manipulation du système de fichiers HDFS

→ Étape 1 : Créer une arborescence de travail

```
➤ hdfs dfs -mkdir -p /user/etudiant/hdfs_test  
➤ hdfs dfs -mkdir -p /data/textes  
➤ hdfs dfs -ls /
```

→ Étape 2 : Ajouter des fichiers dans HDFS

```
➤ echo "Hadoop est un système distribué" > texte1.txt
➤ echo "Le Big Data repose sur HDFS" > texte2.txt
➤ hdfs dfs -put -f texte1.txt texte2.txt /data/textes
```

→ Étape 3 : Explorer le contenu

```
➤ hdfs dfs -ls /data/textes
➤ hdfs dfs -cat /data/textes/texte1.txt
```

→ Étape 4 : Vérifier la réplication

```
➤ hdfs fsck /data/textes/texte1.txt -files -blocks -locations
```

- **But** : voir comment Hadoop découpe les fichiers en blocs et les réplique sur les DataNodes.

Partie 3 — Commandes HDFS essentielles

→ Copie et déplacement

```
➤ hdfs dfs -cp /data/textes/texte1.txt /user/etudiant/hdfs_test/
➤ hdfs dfs -mv /user/etudiant/hdfs_test/texte1.txt /data/
```

→ Suppression

```
➤ hdfs dfs -rm /data/textes/texte2.txt
```

→ Informations sur l'espace

```
➤ hdfs dfs -du -h /
➤ hdfs dfsadmin -report
```

→ Changer les permissions

```
➤ hdfs dfs -chmod -R 755 /data
➤ hdfs dfs -chown -R root:root /data
```

Partie 4 — Lancer et analyser des jobs MapReduce

→ Étape 1 : Job WordCount (compte de mots)

```
➤ hdfs dfs -mkdir -p /wordcount_input
➤ echo "Hadoop simplifie le traitement des grandes données" > wc1.txt
➤ echo "MapReduce permet d'analyser de gros volumes" > wc2.txt
➤ hdfs dfs -put -f wc1.txt wc2.txt /wordcount_input
```

Supprimer la sortie précédente :

```
➤ hdfs dfs -rm -r /wordcount_output
```

Exécuter le job :

```
➤ hadoop jar /opt/hadoop-3.2.1/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.2.1.jar \  
➤ wordcount /wordcount_input /wordcount_output
```

Afficher le résultat :

```
➤ hdfs dfs -cat /wordcount_output/part-r-00000
```

→ Étape 2 : Job “grep” (recherche de mot clé)

```
➤ hdfs dfs -rm -r /grep_output  
➤ hadoop jar /opt/hadoop-3.2.1/share/hadoop/mapreduce/hadoop-mapreduce-examples-3.2.1.jar \  
➤ grep /wordcount_input /grep_output "Hadoop"  
➤ hdfs dfs -cat /grep_output/part-r-00000
```

Partie 5 — Exercices pratiques

Exercice 1

- Créer un dossier `/etudiant/donnees` dans HDFS.
- Ajouter trois fichiers texte.
- Afficher la taille totale avec `hdfs dfs -du -h /etudiant/donnees`.
- Supprimer l’un d’eux et vérifier avec `ls`.

Exercice 2

- Dans `hdfs-site.xml`, modifier :
- `<property>`
- `<name>dfs.replication</name>`
- `<value>2</value>`
- `</property>`
- Redémarrer Hadoop.
- Vérifier la nouvelle réplication :
- `hdfs fsck /data -files -blocks -locations`

Exercice 3

- Créer un dossier `/livres` dans HDFS.
- Ajouter deux fichiers texte (extraits d’un texte long).
- Lancer **WordCount** pour compter le nombre de mots.
- Modifier un fichier et relancer le job → comparer les résultats.

Exercice 4

- Utiliser le job “grep” pour extraire les lignes contenant le mot “**données**”.
- Vérifier le résultat dans `/grep_output`.